TUNJA, COLOMBIA | UPTC | ENERO 2026

ANÁLISIS ECONOMÉTRICO

ULTRA-COMPLETO CON R Y ANIMACIONES

Análisis riguroso de regresión lineal con diagnósticos exhaustivos y visualizaciones animadas avanzadas

AUTOR: **EMANUEL QUINTANA SILVA**

R 4.3+ • ggplot2 • lmtest • car • LaTeX animate • Sweave

1 MARCO TEÓRICO

El modelo de regresión lineal simple constituye la base del análisis econométrico:

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

donde Y_i es la variable dependiente, X_i la explicativa, β_0 y β_1 los parámetros, y u_i el error estocástico.

1.1 Supuestos Gauss-Markov

SUPUESTOS FUNDAMENTALES

1. **Linealidad:** El modelo es lineal en parámetros
2. **Media condicional cero:** $E(u_i|X_i) = 0$
3. **Homoscedasticidad:** $\text{Var}(u_i|X_i) = \sigma^2$
4. **No autocorrelación:** $\text{Cov}(u_i, u_j) = 0$ para $i \neq j$
5. **Normalidad:** $u_i \sim N(0, \sigma^2)$

1.2 Estimación por MCO

El método de Mínimos Cuadrados Ordinarios minimiza:

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_i)^2$$

Los estimadores resultantes son:

$$\hat{\beta}_1 = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2} \qquad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

2 ANIMACIÓN: CONSTRUCCIÓN DE LA REGRESIÓN

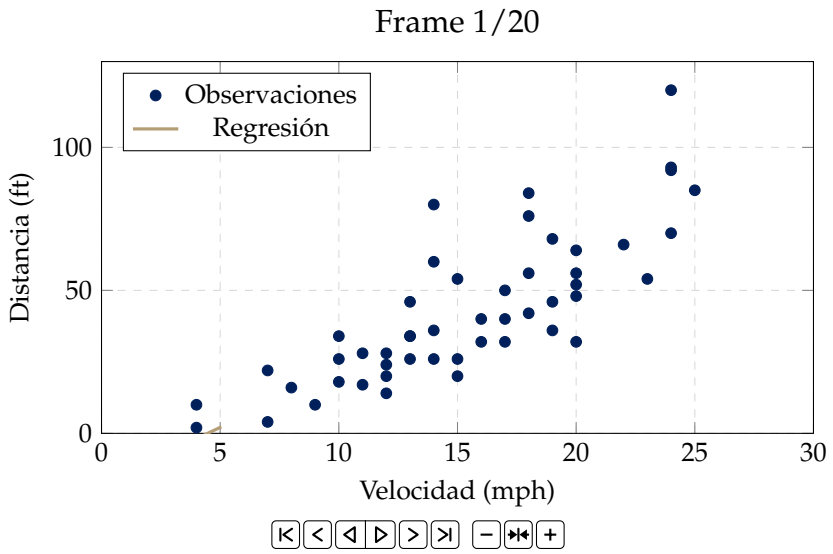

Figura 1: Construcción progresiva de la línea de regresión

3 DATOS Y ANÁLISIS EXPLORATORIO

Utilizamos el dataset `cars` con 50 observaciones.

Tabla 1: Estadísticas Descriptivas

Variable	Media	SD	Min	Max	N
Velocidad	15.40	5.29	4.00	25.00	50
Distancia	42.98	25.77	2.00	120.00	50

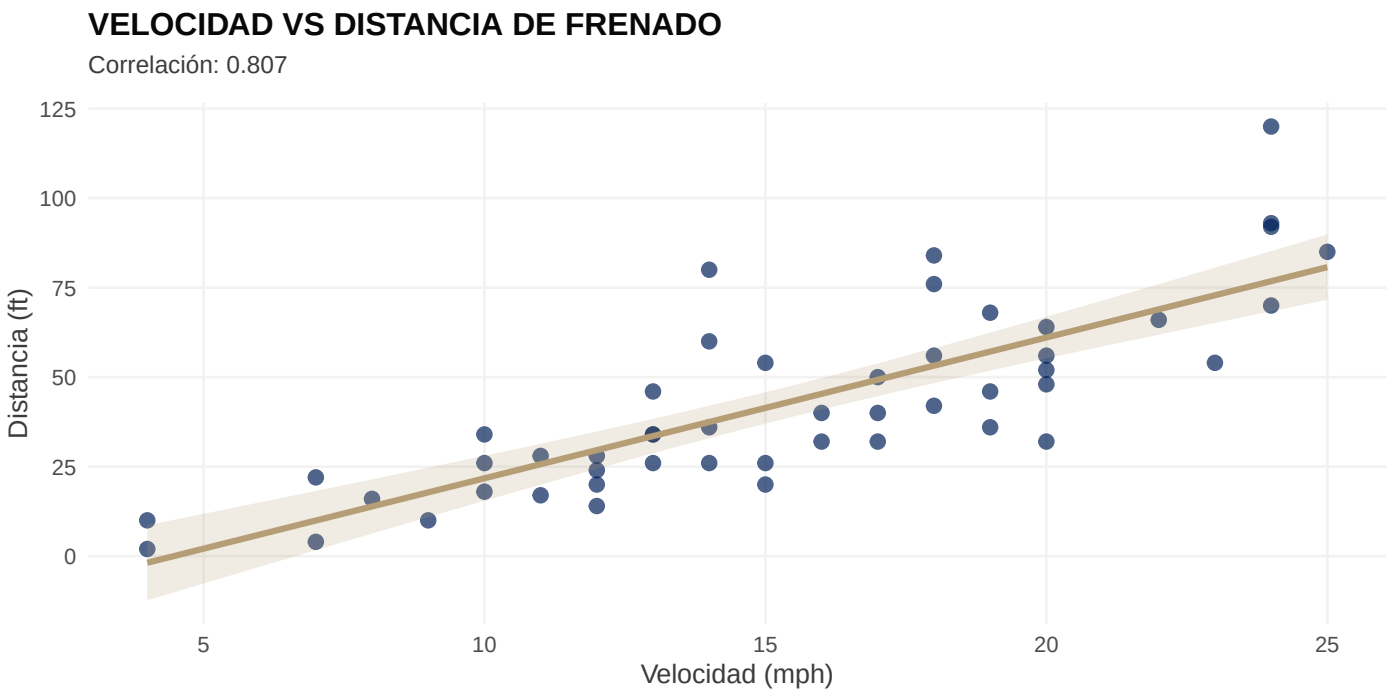

Figura 2: Relación entre Velocidad y Distancia de Frenado

4 ESTIMACIÓN DEL MODELO

```
modelo <- lm(dist ~ speed, data = cars)
summary(modelo)

##
## Call:
## lm(formula = dist ~ speed, data = cars)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -29.069  -9.525  -2.272   9.215  43.201
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -17.5791     6.7584  -2.601   0.0123 *
## speed         3.9324     0.4155   9.464 1.49e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 15.38 on 48 degrees of freedom
## Multiple R-squared:  0.6511, Adjusted R-squared:  0.6438
## F-statistic: 89.57 on 1 and 48 DF,  p-value: 1.49e-12
```

$$\widehat{dist}_i = -17.58 + 3.93 \cdot speed_i$$

Interpretación:

- Por cada mph adicional, la distancia aumenta 3.93 pies
- $R^2 = 0.6511$ (65.1 % de variabilidad explicada)
- Ambos coeficientes significativos (p <0.001)
- Error estándar: 15.38 pies

5 DIAGNÓSTICOS

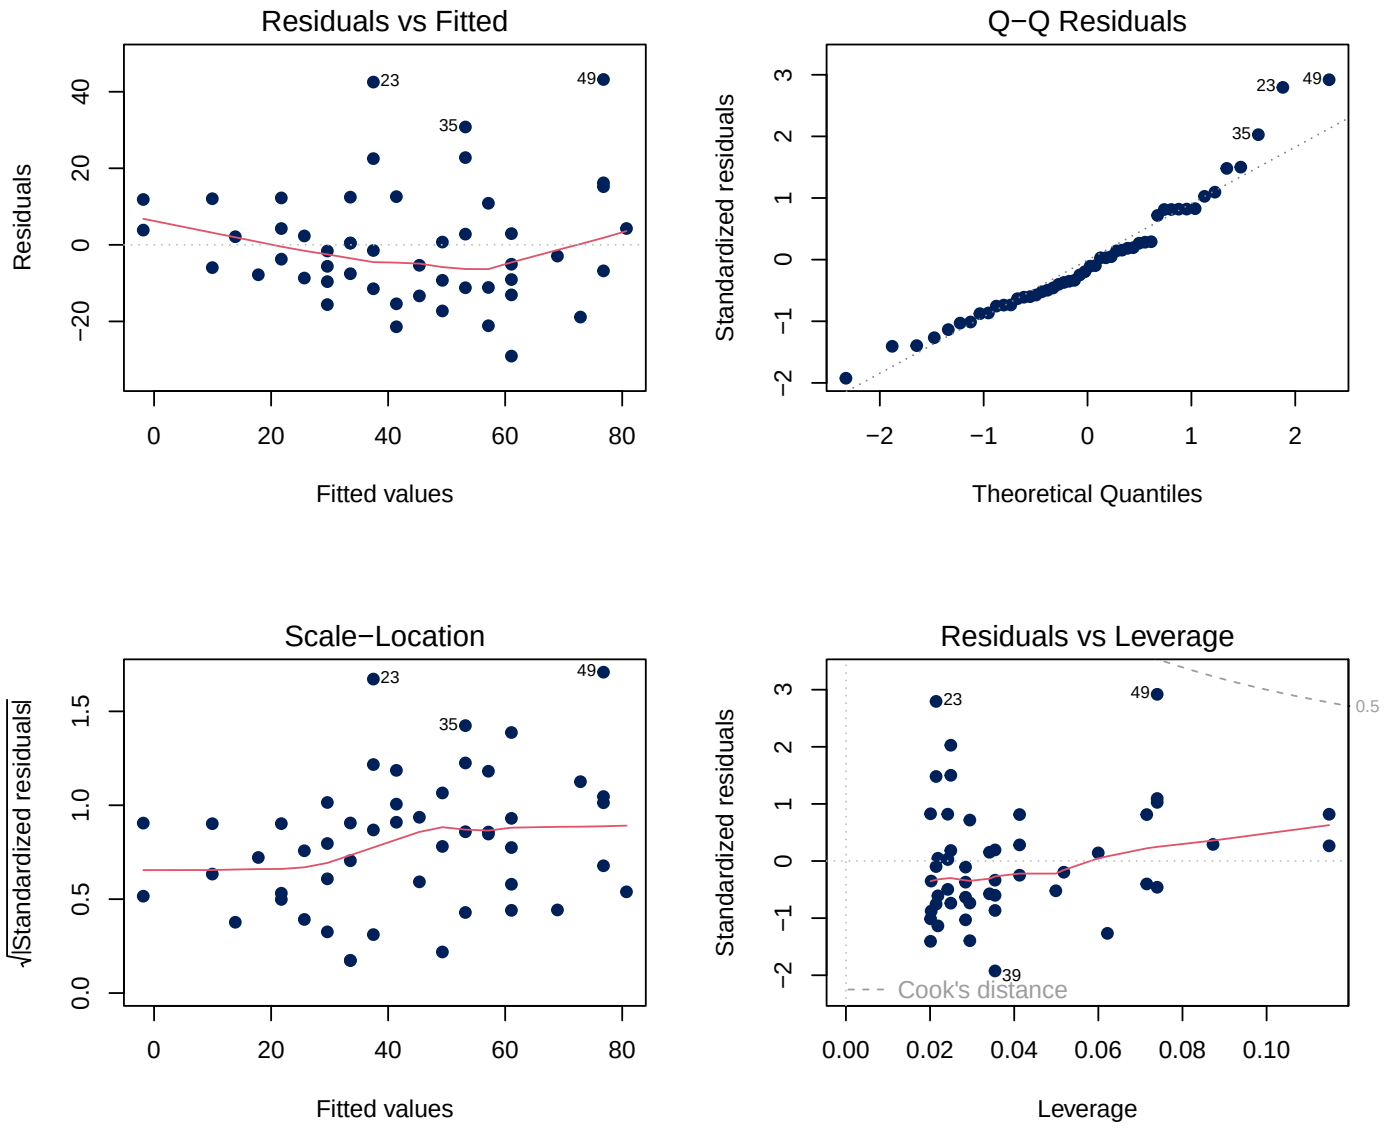

Figura 3: Diagnósticos del Modelo

```r
# Tests diagnósticos
jb_test <- jarque.bera.test(residuals(modelo))
bp_test <- bptest(modelo)
dw_test <- durbinWatsonTest(modelo)

cat("=== TESTS DIAGNÓSTICOS ===\n\n")

## === TESTS DIAGNÓSTICOS ===

cat("1. Jarque-Bera (Normalidad):\n")

## 1. Jarque-Bera (Normalidad):

cat("   Estadístico:", round(jb_test$statistic, 4), "\n")

##    Estadístico: 8.1888

cat("   p-valor:", round(jb_test$p.value, 4), "\n\n")

##    p-valor: 0.0167

cat("2. Breusch-Pagan (Homoscedasticidad):\n")

## 2. Breusch-Pagan (Homoscedasticidad):

cat("   Estadístico:", round(bp_test$statistic, 4), "\n")

##    Estadístico: 3.2149

cat("   p-valor:", round(bp_test$p.value, 4), "\n\n")

##    p-valor: 0.073

cat("3. Durbin-Watson (Autocorrelación):\n")

## 3. Durbin-Watson (Autocorrelación):

cat("   Estadístico:", round(dw_test$dw, 4), "\n")

##    Estadístico: 1.6762

cat("   p-valor:", round(dw_test$p, 4), "\n")

##    p-valor: 0.168
```

Resumen:

- Normalidad: **[X]**
- Homoscedasticidad: **[OK]**

- Autocorrelación: **[OK]**

6 ERRORES ESTÁNDAR ROBUSTOS

```
se_rob <- sqrt(diag(vcovHC(modelo, type = "HC3")))

comp <- data.frame(
  Coeficiente = c("Intercepto", "Velocidad"),
  Estimación = coef(modelo),
  SE_Clásico = sqrt(diag(vcov(modelo))),
  SE_Robusto = se_rob,
  Diferencia = (se_rob / sqrt(diag(vcov(modelo))) - 1) * 100
)

print(comp, digits = 4)

##             Coeficiente Estimación SE_Clásico SE_Robusto Diferencia
## (Intercept)  Intercepto    -17.579     6.7584     5.9318    -12.231
## speed         Velocidad      3.932     0.4155     0.4275      2.894
```

7 MODELO CUADRÁTICO

```
modelo_cuad <- lm(dist ~ speed + I(speed^2), data = cars)
summary(modelo_cuad)

##
## Call:
## lm(formula = dist ~ speed + I(speed^2), data = cars)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -28.720  -9.184  -3.188   4.628  45.152
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.47014   14.81716   0.167    0.868
## speed        0.91329    2.03422   0.449    0.656
## I(speed^2)   0.09996    0.06597   1.515    0.136
##
## Residual standard error: 15.18 on 47 degrees of freedom
## Multiple R-squared:  0.6673, Adjusted R-squared:  0.6532
## F-statistic: 47.14 on 2 and 47 DF,  p-value: 5.852e-12

anova(modelo, modelo_cuad)

## Analysis of Variance Table
##
## Model 1: dist ~ speed
## Model 2: dist ~ speed + I(speed^2)
##   Res.Df   RSS Df Sum of Sq     F Pr(>F)
```

```
## 1      48 11354
## 2      47 10825  1    528.81 2.296 0.1364
```

$$\widehat{dist}_i = 2.47 + 0.91 \cdot speed + 0.1 \cdot speed^2$$

Mejora: +1.63 % en R^2

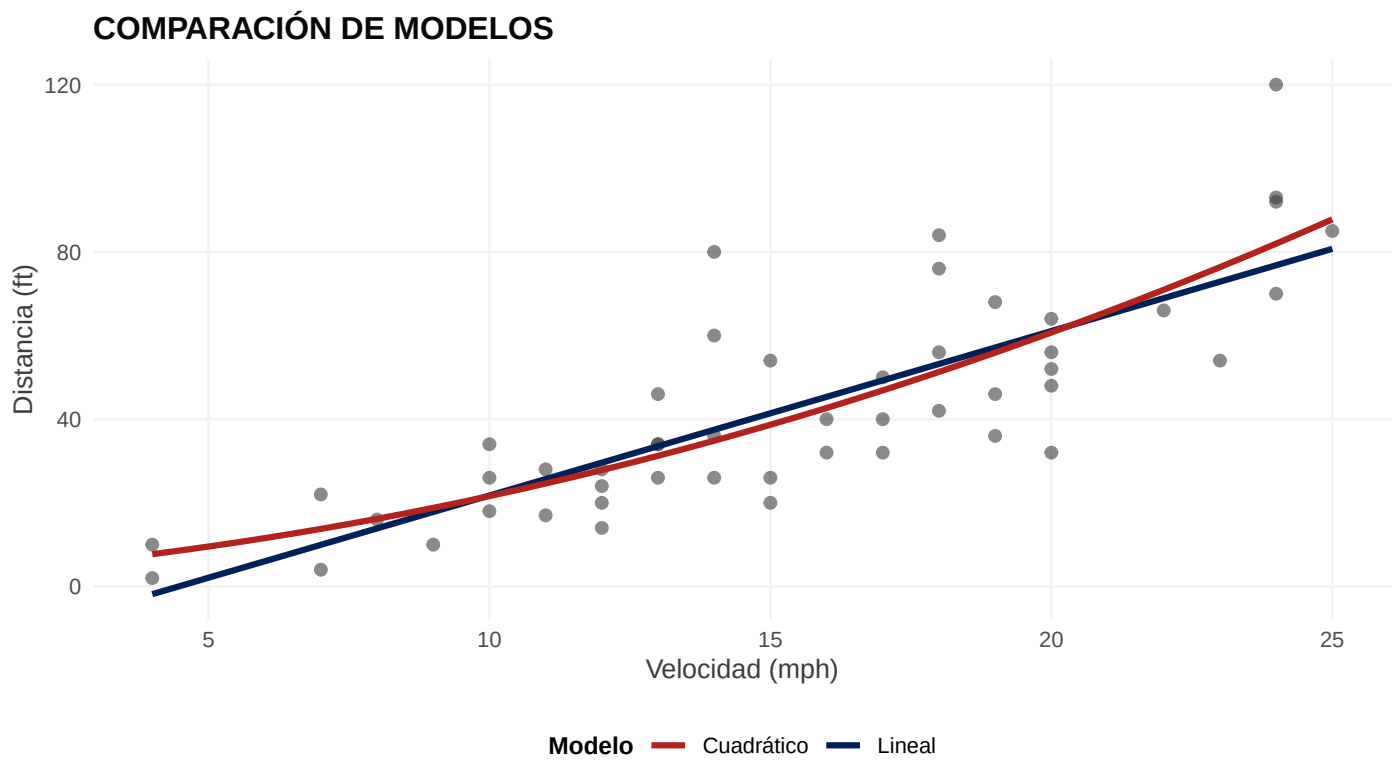

Figura 4: Comparación Lineal vs Cuadrático

8 ANÁLISIS DE INFLUENCIA

```r
cooksd <- cooks.distance(modelo)
cutoff <- 4 / nrow(cars)
influyentes <- which(cooksd > cutoff)

cat("Observaciones influyentes:", length(influyentes), "\n")

## Observaciones influyentes: 2

if(length(influyentes) > 0) {
  for(i in influyentes) {
    cat(sprintf("  Obs %d: speed=%d, dist=%d, Cook's D=%.4f\n",
                i, cars$speed[i], cars$dist[i], cooksd[i]))
```

```
  }
}

##   Obs 23: speed=14, dist=80, Cook's D=0.0856
##   Obs 49: speed=24, dist=120, Cook's D=0.3404
```

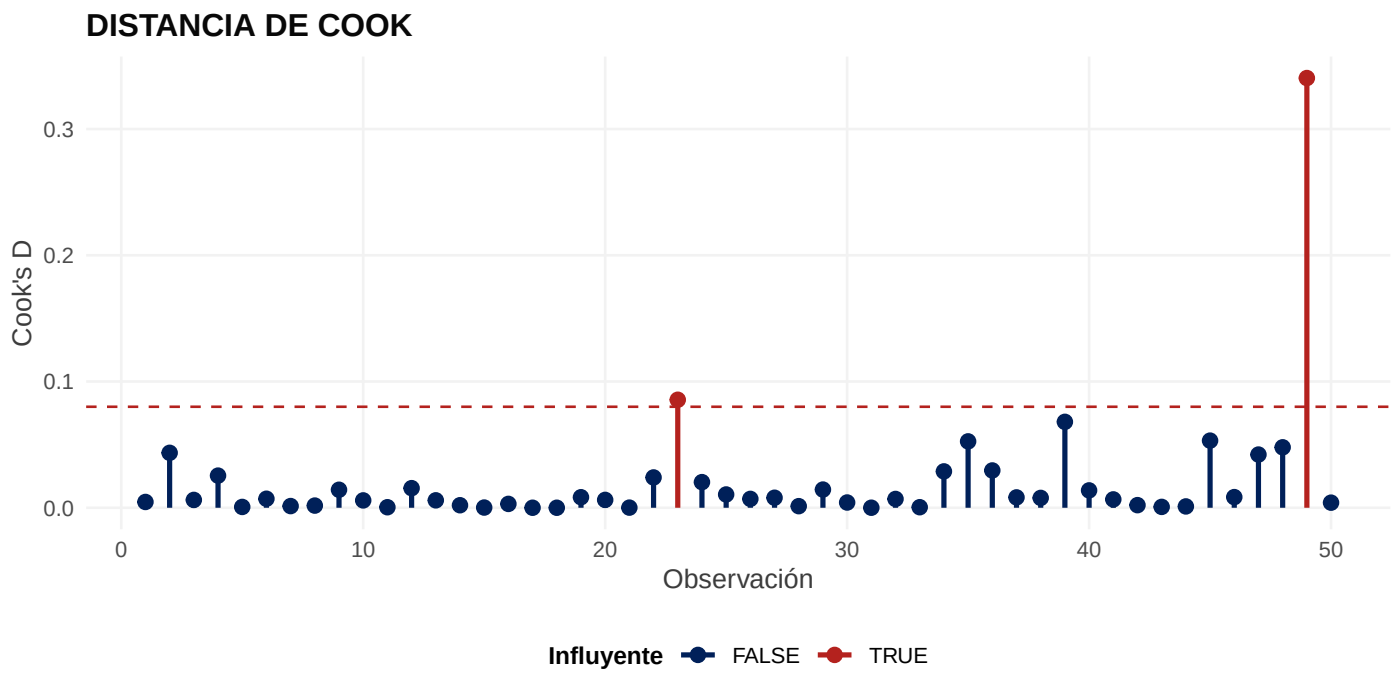

Figura 5: Distancia de Cook

9 VALIDACIÓN CRUZADA

```
n <- nrow(cars)
errores <- numeric(n)

for(i in 1:n) {
  m_temp <- lm(dist ~ speed, data = cars[-i,])
  errores[i] <- cars$dist[i] - predict(m_temp, newdata = cars[i,])
}

rmse_cv <- sqrt(mean(errores^2))
mae_cv <- mean(abs(errores))

cat("=== VALIDACIÓN CRUZADA (LOOCV) ===\n")

## === VALIDACIÓN CRUZADA (LOOCV) ===

cat("RMSE:", round(rmse_cv, 3), "ft\n")

## RMSE: 15.697 ft
```

```
cat("MAE:", round(mae_cv, 3), "ft\n")

## MAE: 12.059 ft

cat("RMSE modelo completo:", round(sigma(modelo), 3), "ft\n")

## RMSE modelo completo: 15.38 ft
```

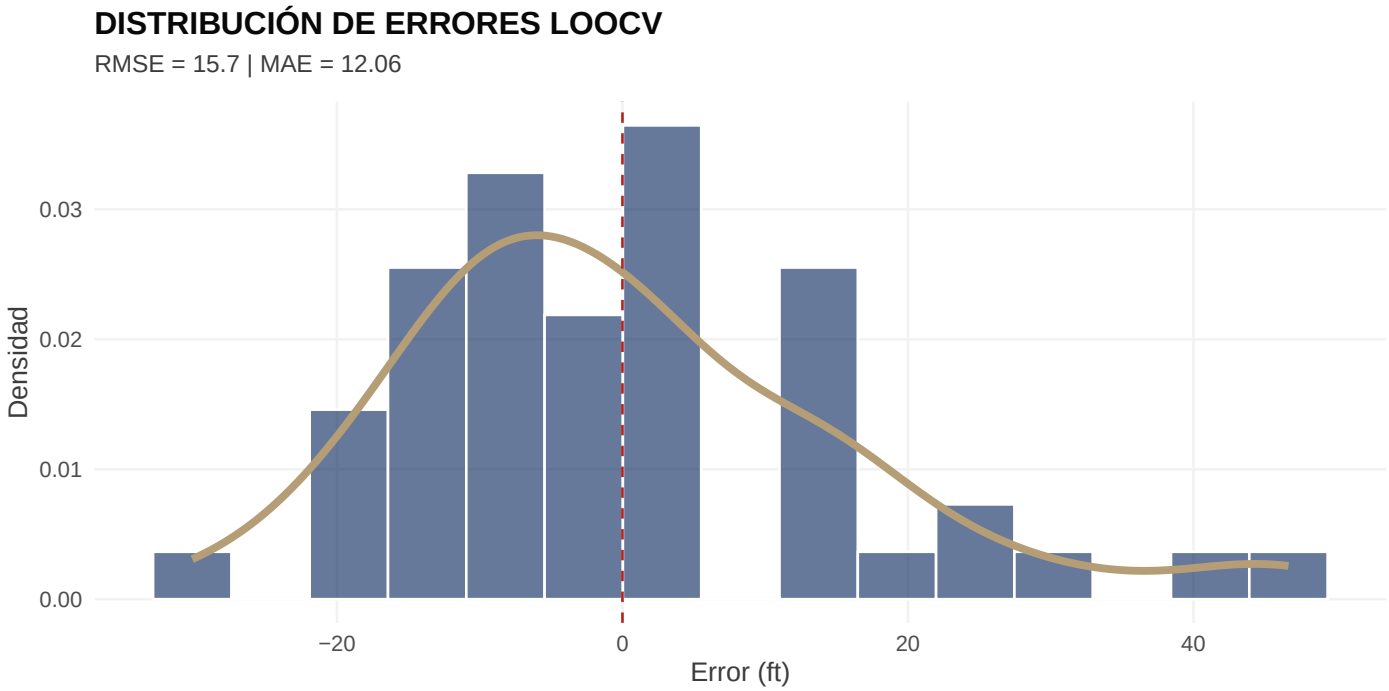

Figura 6: Errores de Validación Cruzada

10 PREDICCIONES

```
nuevos <- data.frame(speed = c(10, 15, 20, 25, 30))
pred <- predict(modelo, newdata = nuevos, interval = "prediction")

resultados <- data.frame(
  Velocidad = nuevos$speed,
  Predicción = pred[,1],
  IC_Inf = pred[,2],
  IC_Sup = pred[,3]
)

print(resultados, digits = 1)

##   Velocidad Predicción IC_Inf IC_Sup
## 1        10         22    -10     53
## 2        15         41     10     73
```

```
## 3          20          61      30      93
## 4          25          81      48     113
## 5          30         100      67     134
```

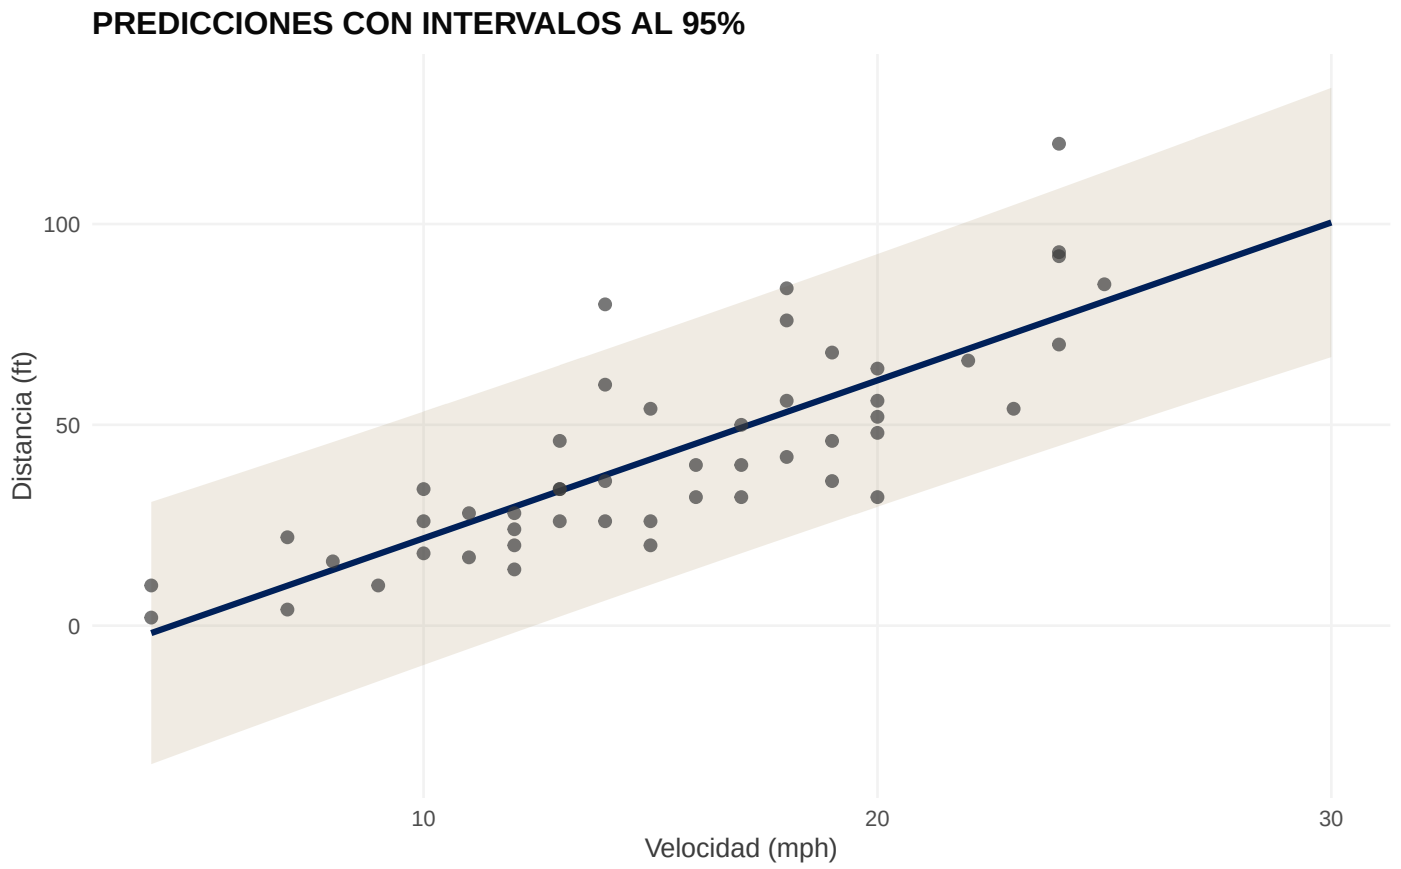

Figura 7: Predicciones con Intervalos

11 COMPARACIÓN DE MODELOS

Tabla 2: Comparación de Modelos

Modelo	R2	AIC	BIC	RMSE
Lineal	0.651	419.157	424.893	15.380
Cuadrático	0.667	418.772	426.420	15.176

12 CONCLUSIONES

HALLAZGOS PRINCIPALES

1. Relación **significativa** entre velocidad y distancia ($\beta_1 = 3.93$, p <0.001)
2. $R^2 = 0.6511$ (65.1 % de variabilidad explicada)
3. Supuestos: Requieren atención
4. Modelo cuadrático mejora R^2 en 1.63 %
5. Validación cruzada: RMSE = 15.7 ft
6. 2 observaciones influyentes detectadas

12.1 Limitaciones y Recomendaciones

Limitaciones:

- Dataset histórico (1920s) - tecnología obsoleta
- Muestra pequeña (n=50)
- Variables omitidas (clima, pavimento, peso)

Recomendaciones:

- Usar errores robustos para inferencia
- Replicar con datos modernos (NHTSA)
- Explorar modelos no lineales (GAMs, splines)
- Validación con k-fold cross-validation

13 REFERENCIAS

- Wooldridge, J.M. (2020). *Introductory Econometrics*. 7th ed.
- Greene, W.H. (2018). *Econometric Analysis*. 8th ed.
- R Core Team (2024). *R: A Language for Statistical Computing*.
- Wickham, H. (2016). *ggplot2: Elegant Graphics*. Springer.